LendingClub 프로젝트: 피처, 기법, 개념 정리

서울대 ABS 14기 팀 프로젝트 · 2026년 11월 9일 기준 · 숫자는 모두 train 데이터 실험 결과

Contents

1 한눈에 보기 **4**
- 1.1 과제와 질문 . . . 4
- 1.2 데이터와 평가 설정 . . . 4

2 피처 정리 **5**
- 2.1 컬럼 지도 . . . 5
- 2.2 핵심 피처 . . . 5
- 2.3 등급 안에 남은 정보 . . . 6
- 2.4 시간에 따른 변화 . . . 7
- 2.5 결측 구조 . . . 7
- 2.6 Feature engineering 결과 . . . 7

3 데이터와 검증 기법 **8**
- 3.1 Data leakage . . . 8
- 3.2 종결 표본 편향과 censoring . . . 8
- 3.3 As-of 학습과 시간 분할 . . . 8
- 3.4 결측 메커니즘 . . . 9

4 수익률과 비교 기준 **10**
- 4.1 네 가지 수익률 정의 . . . 10
- 4.2 Cohort(발행월 묶음) . . . 10
- 4.3 무위험수익률(rf)의 선택 . . . 10

5 모델과 보정 **12**
- 5.1 Logistic regression과 LightGBM . . . 12
- 5.2 기대수익과 LGD . . . 12
- 5.3 확률 보정(calibration) . . . 12

6 평가 지표 **13**
- 6.1 Sharpe ratio와 그 함정 . . . 13
- 6.2 Information ratio . . . 13
- 6.3 RAROC과 EVA . . . 13
- 6.4 꼬리 위험과 효용 . . . 13
- 6.5 선별 곡선 . . . 14
- 6.6 Brinson decomposition . . . 14
- 6.7 예측 지표 . . . 14

7 검증 방법론 **15**

8 앞으로 쓸 기법 **16**
- 8.1 test 평가(고정됨) . . . 16

8.2 남은 후보 16

Chapter 1

한눈에 보기

1.1 과제와 질문

과제는 투자자 관점에서 LendingClub(LC) 대출 중 무엇을 승인할지 정하는 것이다. 기본 지표는 Sharpe ratio지만 변형이 허용되고, accuracy보다 과정과 논리가 중요하다.

이 문서의 결론 세 줄

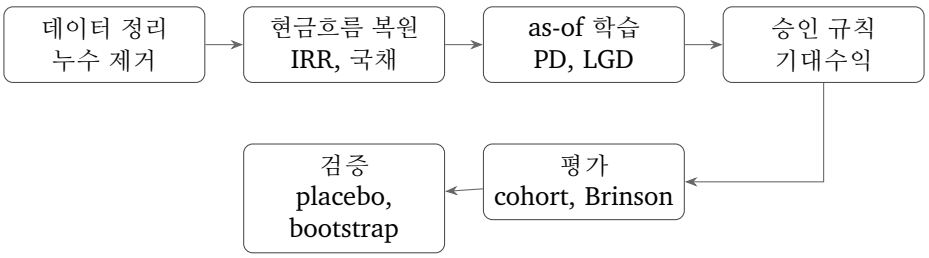
1. 2013~2016년 36개월 대출은 전부 승인해도 수수료 차감 IRR 5.73%로 국채(0.87%)를 이겼다.
2. 모델의 추가 수익은 좋은 등급을 고르는 데가 아니라 **같은 등급 안에서** 더 나은 대출을 고르는 데서 나온다(Brinson decomposition).
3. Feature engineering, tuning, 결측 처리는 결과를 거의 바꾸지 못했다. 차이를 만든 것은 **무엇을 재고 어떻게 검증하느냐**였다.

직관: 모델을 더 똑똑하게 만드는 것보다, 성적표를 정직하게 매기는 법이 더 중요했다.

1.2 데이터와 평가 설정

항목	내용
데이터	train 1,755,294건 × 141 columns, 2007~2020년 발행
결과 상태	Fully Paid 90만, Current 62만, Charged Off 22만. 종결 표본(정책 미충족 제외) 1,116,156건
주 평가 표본	2013~2016년 발행 36개월 종결 대출(종결 비율 99.99%), 발행월 48개
학습 방식	as-of(시점) 학습: 연도 Y의 대출은 Y년 1월 1일까지 확정된 대출로만 학습
수익률	발행월 cohort IRR, 투자자 수수료 1% 차감
비교 기준	발행월·만기를 맞춘 미 국채(GS3, GS5), 보조로 회사채 BAA

Table 1.1: 기본 평가 설정.



Chapter 2

피처 정리

2.1 컬럼 지도

141개 컬럼을 의미와 시점으로 나누면 아래와 같다. 판별 질문은 하나다: “대출을 승인하던 날 이 값을 알 수 있었나?”

그룹	수	대표 컬럼과 역할
대출 조건	15	`int_rate`, `grade`, `sub_grade`, `term`, `loan_amnt`, `purpose`. LC가 매긴 가격 정보 포함
차주 기본 정보	8	`annual_inc`, `dti`, `emp_length`, `home_ownership`, `addr_state`
신용 이력: 연체·공공기록·조회	24	`fico_range_low`, `inq_last_6mths`, `delinq_2yrs`, `mths_since_last_delinq`
신용 이력: 리볼빙·bankcard	21	`revol_util`, `bc_util`, `total_bc_limit`, `percent_bc_gt_75`
신용 이력: 계좌 수·잔액·한도	15	`acc_open_past_24mths`, `total_acc`, `tot_cur_bal`
신용 이력: 할부	9	`il_util`, `num_il_tl`, `total_il_high_credit_limit`
공동신청	15	`sec_app_*`, `annual_inc_joint`. 공동신청일 때만 값이 있음
상환 결과(사후)	16	`total_pymnt`, `recoveries`, `last_pymnt_d`. 누수
hardship 제도(사후)	15	`hardship_*`. 누수
식별·메타	2	`id`, `url`

Table 2.1: 컬럼 그룹(컬럼 사전 기준). 모델 입력 검토 104개, 누수 31개, 제외 후보 2개, 확인 필요 1개, 타깃 1개, 시간 분할 기준 1개.

> **Caution — 누수**
>
> 사후 컬럼을 넣으면 AUC가 0.9999까지 오른다(빼면 0.72). 점수는 완벽해 보이지만 실제 심사 때는 그 값이 없어 쓸모가 없다. 코드에서 컬럼 이름 목록과 테스트로 막아 두었다.

2.2 핵심 피처

2016년 1월 1일 기준 as-of LightGBM(시드 5개 평균)을 2016년 발행 대출에 적용해, 각 피처가 부도 예측에 기여한 크기(평균 |SHAP|)를 쟀다.

순위	피처	뜻	비중	방향
1	int_rate	LC가 매긴 이자율	15.1%	높을수록 위험 ↑
2	annual_inc	자기 신고 연소득	8.0%	높을수록 위험 ↓
3	dti	월 부채 상환액 ÷ 월소득	6.1%	높을수록 위험 ↑
4	addr_state	거주 주	4.1%	범주형
5	earliest_cr_line	첫 신용 계좌 개설 연도	3.1%	해석 주의(아래)
6	term	만기(36/60개월)	2.8%	비선형
7	purpose	대출 목적	2.5%	범주형
8	loan_amnt	신청 금액	2.5%	높을수록 위험 ↑
9	sub_grade	LC 세부 등급	2.5%	범주형
10	mo_sin_old_rev_tl_op	가장 오래된 리볼빙 계좌 경과 개월	2.5%	높을수록 위험 ↓
11	revol_util	리볼빙 한도 대비 사용률	2.2%	높을수록 위험 ↑
12	mths_since_recent_bc	최근 bankcard 개설 후 경과 개월	2.1%	높을수록 위험 ↓
13	total_bc_limit	bankcard 한도 합계	2.1%	높을수록 위험 ↓
14	percent_bc_gt_75	한도 75% 초과 사용 카드 비율	2.0%	높을수록 위험 ↑
15	inq_last_6mths	최근 6개월 신용조회 수	2.0%	높을수록 위험 ↑

Table 2.2: 부도 예측 기여 상위 15개(전체 101개 중). 상위 10개가 49%, 상위 20개가 69%를 차지한다.

핵심 피처에서 읽을 것

- LC 가격 정보(int_rate, grade, sub_grade, term, installment)가 전체 기여의 23%다. 나머지 77%는 다른 변수에 흩어져 있다.
- fico_range_low는 1.5%로 작다. FICO 정보는 이미 등급과 금리에 반영돼 있기 때문이다.
- 그룹으로 묶으면 대출 조건 31%, 차주 기본 정보 23%, 리볼빙·bankcard 20%, 연체·조회 13% 순이다.

직관: LC 금리가 1등이지만, 모델은 금리만 보는 게 아니라 소득·부채·카드 사용 습관을 함께 본다.

Caution — SHAP 방향 읽기

방향은 피처 값과 SHAP의 상관으로 정한 요약이다. 인과가 아니다. 예를 들어 earliest_cr_line(연도)은 "최근일수록 위험 ↓"로 나와 직관과 반대인데, 다른 신용 이력 변수와 겹치는 정보를 나눠 가지면서 생긴 결과일 수 있다. 방향을 주장할 때는 단일 변수 그림(부분 의존도)으로 따로 확인해야 한다.

2.3 등급 안에 남은 정보

등급이 이미 설명한 부분을 빼고, **같은 세부등급 안에서** 부도를 가르는 힘을 쟀다(평가 기간을 보지 않도록 2007~2012년 대출만 사용).

피처	전체 AUC–0.5	등급 안 AUC–0.5	해석
annual_inc	–0.054	–0.080	등급이 소득을 거의 안 씀. 등급 안에서 더 강함
lti(대출액 ÷ 소득)	0.094	0.057	상환 부담
acc_open_past_24mths	0.067	0.051	최근 신용 확장
pti(상환액 ÷ 소득)	0.082	0.049	상환 부담
dti	0.050	0.037	부채 수준
우편번호 부도율	0.033	0.034	등급이 지역을 안 씀
int_rate	0.155	0.013	정보 대부분이 등급과 같음
fico_range_low	–0.105	–0.006	정보 대부분이 등급과 같음
무작위 노이즈	0.002	0.004	기준선

Table 2.3: 세부등급 안 AUC는 세부등급별 AUC의 대출 수 가중 평균. 0이면 정보 없음.

2.4 시간에 따른 변화

- 금리 중앙값: 2013년 14.3% → 2016년 12.0%. 그런데 실제 부도율은 12.2% → 15.9%로 올랐다.
- dti 중앙값: 16.85 → 18.25. 차주의 부채 부담이 커졌다.
- revol_util, bc_util은 2012년 대비 분포 이동이 가장 크다(2018년 PSI 0.34).

직관: 위험은 커지는데 가격은 내려갔다. 과거 데이터로 맞춘 확률이 실제보다 낮게 나온 이유다.

2.5 결측 구조

패턴	LC에서 본 것
구조적 결측	sec_app_*는 개인 신청에서 100% 결측. 단, 공동신청인데도 6%가 비어 있음
사건 없음	mths_since_last_delinq(52%)는 연체 이력이 없어서 빔. 결측 자체가 정보
MNAR 의심	emp_length가 비면 부도율 26.3%, 있으면 19.0%
시기(MAR)	13개 컬럼이 함께 29.8% 결측, 21개 컬럼이 함께 2.4% 결측. 발행 시기로 설명됨
누수	hardship_*가 비어 있으면 부도율이 37%p 낮음(어려움을 겪은 대출에만 값이 생김)

Table 2.4: 결측 패턴(자세한 표는 결측_검증시트.xlsx).

2.6 Feature engineering 결과

상환 부담(pti, lti), 신용 이력 개월 수, 근속 연수 숫자화, 우편번호 부도율을 추가해 as-of 학습으로 다시 평가했다.

> **Caution — 결과: 모두 기각**
>
> 모든 후보의 선별 가치 변화가 –0.01~+0.02%p였다. 같은 모델을 시드만 바꿔 돌린 차이(최대 0.09%p)보다 작았다. EDA에서 본 등급 안 정보는 이미 원본 변수(소득, 상환액, 대출액, 주)에 들어 있었다.
>
> **직관: 피처 하나의 효과보다 모델을 다시 돌렸을 때의 우연한 차이가 더 컸다. 한 번 돌려 본 비교로 피처를 고르면 안 된다.**

Chapter 3

데이터와 검증 기법

3.1 Data leakage

정의

Leakage는 예측 시점에 알 수 없는 정보가 모델 입력에 섞이는 것이다. 시험 전에 정답지를 보는 것과 같다.

직관: 점수가 너무 좋으면 먼저 누수를 의심한다.

3.2 종결 표본 편향과 censoring

Current 대출은 결과를 모른다(**censoring**). 종결 대출만 쓰면, 최근 발행분일수록 일찍 끝난 대출(부도 포함)만 남아 부도율이 부풀려진다. 결과를 모르는 대출까지 쓰는 표준 방법이 **competing risks**(부도 vs 상환) 누적 발생률이다.

Aalen–Johansen 누적 부도율

$$S(t) = \prod_{u \le t} \Big(1 - \frac{d_1(u) + d_2(u)}{n(u)}\Big), \qquad \mathrm{CIF}_1(t) = \sum_{u \le t} S(u-1)\,\frac{d_1(u)}{n(u)}$$

$n(u)$: u개월째 위험 집합, d_1: 부도, d_2: 상환.

3.3 As-of 학습과 시간 분할

연도 Y의 대출을 고를 때는 Y년 1월 1일 이전에 발행되고 그 전에 결과가 확정된 대출로만 학습한다. 부도는 마지막 납부 후 약 5개월 뒤 상각되므로 그만큼 늦게 확정된다고 본다.

분할 방식	AUC	해석
무작위 분할	약 0.73	미래 정보가 섞여 낙관적
as-of 시간 분할	0.62~0.68	실제 투자 상황에 가까움

Table 3.1: 같은 LightGBM의 예측력.

Caution — 가정이 결과를 바꾼다

상각 지연을 5개월로 두면 2016년 초 학습 표본의 부도율은 17.4%로 최종 18.1%보다 낮다. 지연을 0으로 두면 22.2%로 높다. 편향의 방향이 가정에 달려 있다.

3.4 결측 메커니즘

유형	뜻
MCAR	Missing completely at random. 완전히 우연한 결측
MAR	Missing at random. 관측된 다른 변수로 설명되는 결측(예: 발행 시기)
MNAR	Missing not at random. 빠진 값 자체 때문에 빔. 데이터만으로 증명 불가
구조적	해당 사항이 없어서 빔(예: 개인 신청의 공동신청 컬럼)

Table 3.2: 결측 유형.

> **In practice — Target encoding**
>
> 우편번호처럼 범주가 많은 변수는 범주별 부도율로 바꿔 쓸 수 있다. 이때 자기 행의 정답을 쓰지 않도록 **out-of-fold**로 계산하고, 건수가 적은 범주는 전체 평균 쪽으로 **smoothing**한다.

Chapter 4

수익률과 비교 기준

4.1 네 가지 수익률 정의

같은 대출도 정의에 따라 수익률이 크게 달라진다. 2013년 발행분 기준으로 비교한다.

정의

$$\text{단순 연환산:}\quad r = \left(\frac{\text{총 상환액}}{\text{대출액}}\right)^{12/T} - 1$$

$$\text{IRR:}\quad \sum_{k=0}^{H} \frac{CF_k}{(1+m)^k} = 0, \qquad \text{IRR} = (1+m)^{12} - 1$$

$$\text{재투자 수익률:}\quad FV = \sum_{k} CF_k (1+g)^{T-k}, \qquad R = (FV/P)^{12/T} - 1$$

정의	2013년	가정
수업식(부도면 0)	11.9%	부도의 원금 손실을 무시
단순 연환산(우승 논문)	2.8%	매달 돌려받은 원리금이 놀고 있다고 봄
국채 재투자	3.3%	돌려받은 돈을 국채에 넣음
통합 IRR(수수료 1% 후)	8.9%	돌려받은 돈을 같은 수익률로 재투자
국채(3년)	0.8%	비교 기준

Table 4.1: 같은 대출, 네 가지 숫자.

Example — 왜 단순 연환산은 낮게 나오나

Step 1. 금리 12%, 36개월, 약정대로 다 갚은 대출의 월 납입금은 원금의 약 3.32%다. [개념: 원리금 균등 상환]

Step 2. 총 상환액 ÷ 원금 ≈ 1.196, 단순 연환산은 $1.196^{1/3} - 1 \approx 6.1\%$.

Step 3. 하지만 돈은 매달 돌아오므로 실제 수익률(IRR)은 $1.01^{12} - 1 = 12.7\%$다. [개념: IRR]

답 단순 연환산은 돌려받은 돈을 다시 투자하지 않는다고 보기 때문에 약정 금리의 절반 정도로 나온다.

4.2 Cohort(발행월 묶음)

같은 달에 발행된 대출을 하나의 포트폴리오로 보고 IRR을 계산한다. 발행월 사이의 차이가 곧 "언제 투자했느냐"의 위험이다.

4.3 무위험수익률(rf)의 선택

과제가 정한 기준은 국채다. 어떤 국채를 쓸지는 우리가 고른다.

기준	평균	전부 승인 초과수익	메모
3개월 국채	0.15%	+5.62%p	교과서적 rf
만기 맞춘 국채(기본)	0.94%	+4.86%p	과제 정의에 충실
국채 +3%p	3.94%	+1.86%p	유동성 보상 가정
회사채 BAA	4.91%	+0.81%p	17개 발행월에서 회사채보다 낮음

Table 4.2: 비교 기준을 바꾸면 결론의 강도가 바뀐다.

Caution — 회사채는 rf가 아니다

회사채를 빼서 계산한 비율은 Sharpe가 아니라 **information ratio**다. BAA는 장기채이고 약속 수익률이라 LC에 불리한 비교다.

Chapter 5

모델과 보정

5.1 Logistic regression과 LightGBM

- **Logistic regression**: 해석이 쉬운 기준 모델. 학습 데이터가 적은 해(2013년)에는 LightGBM보다 나았다(AUC 0.646 vs 0.623).
- **LightGBM**: gradient boosting tree. 파라미터는 고정하고(튜닝 효과 약 0.001), 시드 5개의 예측을 평균한다.
- 실전 조건에서는 금리만 쓴 모델도 비슷한 예측력을 보였다. 복잡한 모델의 가치는 수익보다 **손실 꼬리를 줄이는 데** 있었다(승인 부도율 14.5% → 12.4%).

5.2 기대수익과 LGD

연 기대수익(근사)

$$E[r] = (1-\hat{p})\, r_{\text{약정}} - \hat{p} \cdot \text{LGD}$$

$\hat{p}$: 예측 부도확률, LGD: 부도 시 손실률(그 시점 확정 부도 대출 평균).

5.3 확률 보정(calibration)

as-of 학습 확률은 수준이 틀렸다(2013년 예측 6.1% vs 실제 12.2%). 세 방법을 시험했다.

- **Isotonic regression**: 예측값과 실제 결과를 단조 함수로 맞춤
- **만기 도달 보정**: 그 시점에 이미 만기까지 지켜본 대출로만 맞춤
- **Logit shift**: $\operatorname{logit}\hat{p}' = \operatorname{logit}\hat{p} + c$, 평균이 생존분석 추정치가 되게 c를 고름

> **Caution — 결과: 모두 실패**
>
> 원인은 표본 편향보다 **신용 악화**였다. 과거에 맞추는 보정은 추세를 따라가지 못한다. 대신 PD 과소추정과 LGD 과대추정(시점 52~62% vs 실제 36.5%)이 서로 상쇄돼, 보정하지 않은 조합이 투자 성과가 가장 좋았다.

Chapter 6

평가 지표

6.1 Sharpe ratio와 그 함정

과제식 Sharpe와 항등식

$$\mathrm{SR} = \frac{\bar{x}}{s_x}, \quad x_i = a_i e_i \qquad \Longrightarrow \qquad \mathrm{SR} = \frac{\sqrt{a}\, m}{\sqrt{s^2 + (1-a)m^2}}$$

a: 승인 비율, m, s: 승인 대출 초과수익의 평균·표준편차, 거절 자금은 초과수익 0.

역U자의 정체

승인 비율이 줄면 $\sqrt{a}$ 때문에 SR이 기계적으로 변한다. 무작위로 25%만 승인해도 SR이 –0.122에서 –0.061로 약 $\sqrt{0.25}$배가 됐다. 선별 실력과 투자 비중 효과가 섞여 있다.

6.2 Information ratio

$$\mathrm{IR} = \frac{\overline{R - B}}{s_{R-B}}$$

비교 지수 B(예: 회사채) 대비 초과수익의 안정성이다. 회사채 기준으로 보면 선별 규칙의 IR은 1.90, 전부 승인은 1.08이었다.

6.3 RAROC과 EVA

은행 관점

$$\mathrm{RAROC} = \frac{r - \mathrm{EL} - f - o}{K}, \qquad \mathrm{EVA} = r - \mathrm{EL} - f - o - hK$$

$$K = \mathrm{LGD}\left[N\left(\frac{G(\mathrm{PD}) + \sqrt{R}\, G(0.999)}{\sqrt{1-R}}\right) - \mathrm{PD}\right], \quad R = 0.03w + 0.16(1-w)$$

EL: 예상손실, f: 조달비용, o: 운영비, h: 요구수익률, K: Basel 기타 소매 자본, $w = \frac{1-e^{-35\mathrm{PD}}}{1-e^{-35}}$.

Caution — 주 지표로 쓰지 않은 이유

기본 가정에서 RAROC 중앙값이 94%라 대출의 99%를 승인했다. 결과가 데이터보다 비용·자본 가정에 좌우된다.

6.4 꼬리 위험과 효용

- **CVaR(하위 5% 평균)**: 최악 구간의 평균 손실. 대출 수익은 모든 등급에서 음의 skewness다.
- **Sortino ratio**: 하방 변동성만 위험으로 본다. 이번 데이터에서는 Sharpe와 순위가 거의 같았다.
- **확실성 등가**: $\mathrm{CE} = \bar{X} - \frac{\gamma}{2}\mathrm{Var}(X)$. 위험회피 $\gamma = 50$에서도 최적은 전부 승인이었다. 분산된 포트폴리오에서는 규모가 위험보다 중요하다.

6.5 선별 곡선

선별 가치

$$\mathrm{SV} = \frac{1}{|Q|}\sum_{q\in Q}\left[\mathrm{ER}_{\mathrm{model}}(q) - \mathrm{ER}_{\mathrm{random}}(q)\right], \quad Q = \{0.1, \ldots, 0.9\}$$

$\mathrm{ER}(q)$: 점수 상위 q를 승인했을 때 승인 대출의 국채 대비 초과 IRR.

기대수익 순위의 SV는 1.03%p(95% 구간 0.95~1.12), 부도확률 순위는 0.22%p였다. 임계값을 고르는 자의성이 없다. 같은 생각은 profit scoring(Serrano-Cinca & Gutiérrez-Nieto, 2016), EMP(Verbraken 외, 2014)에 이미 있다.

6.6 Brinson decomposition

배분 · 선별 · 상호작용

$$\text{배분} = \sum_g (w_g^s - w_g^b)(R_g^b - R^b), \qquad \text{선별} = \sum_g w_g^b (R_g^s - R_g^b),$$
$$\text{상호작용} = \sum_g (w_g^s - w_g^b)(R_g^s - R_g^b)$$

g: 등급(또는 세부등급), w: 금액 비중, R: pooled IRR, s: 전략, b: 전부 승인.

결과

세부등급 35개 기준 등급 안 선별 효과가 2014~2016년 0.69~1.11%p, 2017년 1.64%p였고, 배분 효과는 0~0.23%p였다. 2013년만 배분이 더 컸다.

직관: 펀드매니저로 치면 "좋은 업종을 많이 산" 사람이 아니라 "같은 업종 안에서 좋은 종목을 고른" 사람이다.

6.7 예측 지표

- **AUC**: 부도와 정상을 순위로 얼마나 잘 가르는지. 0.5는 동전 던지기.
- **Brier score**: $\frac{1}{n}\sum(\hat{p}_i - y_i)^2$. 확률 수준까지 본다.
- **ECE**: 예측 구간별 (평균 예측 – 실제 비율)의 가중 평균. 보정이 맞는지 본다.
- **PSI**: $\sum(b-a)\ln(b/a)$. 분포가 시간에 따라 얼마나 이동했는지. 0.1 이상이면 의미 있는 변화.

Chapter 7

검증 방법론

기법	하는 일
Placebo(무작위 승인)	선별 실력이 없으면 성과가 0이 나와야 함. 평가 방법이 가짜 성과를 만들지 않는지 확인
Placebo(라벨 섞기)	정답을 섞어 학습한 모델은 선별 가치가 0 근처여야 함(실제 0.01%p)
시드 반복	같은 모델을 시드 5개로 돌려 결론이 우연인지 확인
Block bootstrap	발행월 단위로 다시 뽑아 95% 신뢰구간 계산(같은 달 대출은 함께 움직임)
보류 구간	한 번도 안 쓴 구간(2017년)에서 같은 방향이 나오는지 확인
사전 등록	test를 받기 전에 가설·규칙·성공 기준을 고정(태그 `test-protocol-v1`)
주장 장부	주장마다 근거와 상태(지지/잠정/기각)를 기록(`docs/research_log.md`)

Table 7.1: 결론을 지키는 장치들.

> **Caution — 데이터 엿보기**
>
> 같은 평가 구간을 여러 번 쓰면, 그 구간에 맞춘 결론을 고르게 된다. 지금까지 비교한 규칙·지표 조합은 60개 이상이다. 그래서 최종 판단은 아직 안 본 공식 test로만 한다.

Q. 결론이 틀렸던 적은?

있다. "부도확률 순위는 무작위와 비슷하다"는 시드 하나로 본 착각이었다. 시드 5개와 부트스트랩으로 보니 유의하게 양수였고, 해마다 커졌다(2017년 2.00%p). 그래서 기각하고 기록했다.

Chapter 8

앞으로 쓸 기법

8.1 test 평가(고정됨)

가설	지지 기준
H1 성과 귀속	2013~16년 통합 등급 안 선별 > 0이고 배분보다 크며, 4개 연도 중 3개 이상 양수
H2 선별 가치	기대수익 순위 SV의 95% 구간 하한 > 0
H3 국채 대비	전부 승인이 발행월의 90% 이상에서 국채보다 높음
H4 회사채 대비	선별 규칙의 BAA 이하 발행월 수 < 전부 승인

Table 8.1: 주 승인 규칙은 "기대수익 > 만기 국채"(R1).

8.2 남은 후보

- **거시 변수**: 실업률 등으로 신용 악화를 설명할 수 있는지. 독립 관측이 48개월뿐이라 약할 수 있다.
- **60개월 대출 확장**: 종결 편향을 처리해야 한다.
- **조기상환 모형**: 정상 상환의 76%가 조기상환이다. 부도 다음으로 큰 수익 변수다.
- **Partial dependence**: 핵심 피처의 방향을 단일 변수 그림으로 확인한다.

> **In practice — 이 문서의 숫자**
>
> 모든 숫자의 근거 파일은 `docs/decisions.md`와 `results/` 폴더에 있다. 피처 중요도는 `scripts/17_feature_importance.py`, 결측 표는 `docs/결측_검증시트.xlsx`로 다시 만들 수 있다.